

chinatax-crawler

python 3.9+

license MIT

国家税务总局「税案通报」栏目爬虫

从 [国家税务总局网站](#) 的「税案通报」栏目自动抓取税务案例数据，输出结构化 JSON / JSONL / CSV 数据集。

功能特性

- 🔍 **自动发现** — 自动检测总页数，无需手动指定
- 📄 **正文提取** — 解析文章页 HTML，提取标题、正文、来源、日期、责任编辑
- 📁 **多格式导出** — 支持 JSON、JSONL（适合大数据集）、CSV 三种格式
- ⏮ **断点续传** — 中断后自动从检查点恢复，不重复抓取
- 🔄 **自动重试** — 指数退避重试，应对网络波动
- 📊 **进度条** — tqdm 实时显示进度
- ⚙ **灵活配置** — CLI 参数 + 环境变量双重覆盖
- 📦 **轻量依赖** — 仅需 `requests` + `beautifulsoup4` + `tqdm` + `lxml`

快速开始

安装

```
# 克隆仓库
git clone https://github.com/user/chinatax-crawler.git
cd chinatax-crawler

# 创建虚拟环境（推荐）
python -m venv .venv
.venv\Scripts\activate # windows
source .venv/bin/activate # macOS/Linux

# 安装依赖
pip install -e .
```

基本使用

```
# 完整抓取（列表 + 文章正文）→ data/chinatax_cases.json
python -m chinatax_crawler

# 仅抓取索引列表 → data/chinatax_cases_index.json
python -m chinatax_crawler --list

# 输出 CSV 格式
python -m chinatax_crawler --format csv

# 测试模式：只抓取前 20 篇
```

```
python -m chinatax_crawler --max 20

# 慢速抓取（间隔 2 秒），避免被限流
python -m chinatax_crawler --delay 2.0
```

命令行参数

参数	说明	默认值
<code>--list</code>	仅抓取索引（不抓正文）	—
<code>--format json\ jsonl\ csv</code>	输出格式	<code>json</code>
<code>--output, -o NAME</code>	输出文件名（不含扩展名）	<code>chinatax_cases</code>
<code>--data-dir DIR</code>	数据输出目录	<code>./data</code>
<code>--delay FLOAT</code>	请求间隔（秒）	<code>1.0</code>
<code>--timeout INT</code>	请求超时（秒）	<code>30</code>
<code>--max N</code>	最多抓取 N 篇文章	<code>0</code> （不限）
<code>--no-resume</code>	禁用断点续传	—
<code>--log-level DEBUG\ INFO\ ...</code>	日志级别	<code>INFO</code>
<code>--log-file PATH</code>	日志文件路径	—

环境变量

所有配置项均可通过环境变量 `CHINATAX_*` 覆盖：

```
# Windows PowerShell
$env:CHINATAX_REQUEST_DELAY = "2.0"
$env:CHINATAX_OUTPUT_FORMAT = "csv"

# Linux/macOS
export CHINATAX_REQUEST_DELAY=2.0
export CHINATAX_OUTPUT_FORMAT=csv
```

输出数据格式

JSON (`chinatax_cases.json`)

```
[
  {
    "article_id": "c5249875",
    "title": "税务部门集中曝光8起私户收款偷税案件",
    "url":
"http://www.chinatax.gov.cn/chinatax/n810219/c102025/c5249875/content.html",
    "publish_date": "2026-05-22",
    "source": "国家税务总局办公厅",
    "content_html": "<p>...</p>",
  }
]
```

```
"content_text": "近年来，税务部门认真贯彻...",
"editor": "曾彪",
"crawler_ts": "2025-01-15T10:30:00.123456"
}
]
```

CSV (chinatax_cases.csv)

article_id	title	url	publish_date	source	editor	content_text
c5249875	税务部门集中曝光...	http://...	2026-05-22	国家税务总局办公厅	曾彪	近年来...

项目结构

```
chinatax-crawler/
├─ chinatax_crawler/
│   ├── __init__.py      # 包入口
│   ├── __main__.py      # CLI 接口
│   ├── config.py        # 配置管理
│   ├── crawler.py       # 爬虫引擎
│   ├── parser.py        # HTML 解析器
│   ├── storage.py       # 数据存储
│   └─ utils.py          # 工具函数
├─ data/                 # 输出数据 (gitignored)
├─ tests/                # 测试
├─ pyproject.toml        # 项目元数据
├─ README.md
├─ LICENSE
└─ .gitignore
```

数据规模

- 约 **55 页** 列表
- 每页约 **20 篇** 文章
- 总计约 **1,100 篇** 税案通报
- 覆盖时间范围：约 2017 年至今

注意事项

1. **遵守 robots.txt** — 本爬虫遵循目标网站的爬取规则
2. **合理速率** — 默认请求间隔 1 秒，请勿设置过低
3. **非商业用途** — 数据版权归国家税务总局所有，请合理使用
4. **网络环境** — 部分网络可能需要代理访问 gov.cn 域名

开发

```
# 安装开发依赖
pip install -e ".[dev]"

# 代码检查
ruff check chinatax_crawler/

# 运行测试
pytest tests/ -v
```

License

MIT License — 详见 [LICENSE](#) 文件。

 **免责声明：**本项目仅用于学习和研究目的。爬取的数据版权归 [国家税务总局](#) 所有。使用者应遵守相关法律法规和目标网站的 robots.txt 规定。